Predição do resultado eleitoral a partir de snapshots da apuração

Resumo conceitual para discussão estatística - desenho dos dados, três modelos e objetivo preditivo

Ideia central
Salvar estados sucessivos da apuração (10%, 20%, 30% ... 100%) e usar a dinâmica temporal + diferenças geográficas para estimar o resultado final antes que todos os municípios tenham sido totalizados.

Objetivo científico

A apuração parcial não é uma amostra aleatória do eleitorado: municípios e regiões entram na totalização em momentos diferentes. Se áreas que chegam mais tarde possuem perfil eleitoral sistematicamente distinto, o resultado nacional pode se deslocar ao longo das horas. O estudo pretende medir esse viés de composição e antecipar o resultado final, inclusive de municípios ainda pouco ou nada apurados.

Três modelos propostos

MODELO	O QUE FAZ	OBJETIVO
1. Extrapolação proporcional	Em um snapshot (ex.: BR = 20%), usa o percentual já observado no município como aproximação do resultado final e projeta o total de votos/participação.	Baseline simples e transparente. Mede quanto erro existe ao supor que a parcela já apurada representa o município inteiro.
2. Swing / correção histórica	Aprende o deslocamento entre parcial e final e também relações históricas entre município, capital, estado e eleições anteriores.	Estimar o “shift” esperado ao longo da apuração e corrigir o baseline.
3. ML para votos remanescentes / município ainda não apurado	XGBoost, Random Forest ou similares usam resultado da capital/estado, relação histórica município-capital, características socioeconômicas, geografia, ritmo de apuração e eventual resultado parcial local.	Prever o resultado final do município antes de ele estar suficientemente apurado - ou mesmo antes de entrar na totalização.

Formulação preferida para o ML

Em vez de pedir ao modelo apenas o percentual final, pode-se prever a correção até o resultado final: Δ = share_final − share_atual. Outra formulação ainda mais direta é estimar a composição dos votos que ainda faltam e somá-los aos já observados. Isso modela explicitamente o efeito de regiões que entram mais tarde.

Resultado da capital / estado	Relação histórica município ↔ capital	Características socioeconômicas e geográficas	Resultado parcial / ritmo da apuração
↓	↓	↓	↓
Modelo preditivo → resultado final esperado do município / votos remanescentes			

Como salvar os dados

A estrutura deve preservar o dado bruto e, ao mesmo tempo, facilitar análises longitudinais e treinamento de modelos.

1. RAW	Guardar cada snapshot original da plataforma em JSON comprimido (ex.: snapshot_020.json.zst). É a fonte imutável para auditoria e reprocessamento.
2. NORMALIZED	Converter para Parquet longitudinal: cada linha = eleição × turno × cargo × snapshot × município × candidato. Manter votos, progresso local/UF/BR e horário.
3. FEATURES / ANALYTICS	Gerar tabelas derivadas: deltas entre snapshots, votos novos entre 20→30%, correção até 100%, histórico eleitoral, características municipais e variáveis município↔capital.

Exemplo de tabela longitudinal

A mesma cidade aparece várias vezes: uma linha para cada candidato em cada snapshot. Isso mantém o tempo como dimensão do banco, permite calcular deltas e torna a estrutura compatível com modelos estatísticos e de machine learning.

Exemplo de 1 município em Parquet (formato longitudinal)

eleição	turno	cargo	snapshot	pct_alvo	pct_real_BR	UF	cod_mun_TSE	município	progresso_mun	candidato	votos	votos_validos	share
2026	1	PRESIDENTE	10	10	10,37	SP	64254	Ribeirão Preto	14,2	Candidato A	21.430	52.120	41,15%
2026	1	PRESIDENTE	10	10	10,37	SP	64254	Ribeirão Preto	14,2	Candidato B	25.910	52.120	49,71%
2026	1	PRESIDENTE	10	10	10,37	SP	64254	Ribeirão Preto	14,2	Candidato C	4.780	52.120	9,17%
2026	1	PRESIDENTE	20	20	20,18	SP	64254	Ribeirão Preto	29,8	Candidato A	45.930	111.250	41,29%
2026	1	PRESIDENTE	20	20	20,18	SP	64254	Ribeirão Preto	29,8	Candidato B	54.730	111.250	49,20%
2026	1	PRESIDENTE	20	20	20,18	SP	64254	Ribeirão Preto	29,8	Candidato C	10.590	111.250	9,52%
2026	1	PRESIDENTE	30	30	30,12	SP	64254	Ribeirão Preto	44,7	Candidato A	69.880	169.900	41,13%
2026	1	PRESIDENTE	30	30	30,12	SP	64254	Ribeirão Preto	44,7	Candidato B	83.680	169.900	49,25%
2026	1	PRESIDENTE	30	30	30,12	SP	64254	Ribeirão Preto	44,7	Candidato C	16.340	169.900	9,62%

Cada linha representa uma combinação snapshot × município × candidato.

Exemplo de registro: eleição=2026 | turno=1 | cargo=Presidente | snapshot=20 | município=Ribeirão Preto | candidato=A | votos=45.930 | progresso_mun=29,8% | progresso_BR=20,18%

O que os snapshots permitem medir

- Erro do baseline: diferença entre o percentual parcial e o resultado final de cada município.
- Curva de convergência: como 10%, 20%, 30%... evoluem até 100%.
- Composição dos lotes novos: quais municípios e perfis eleitorais entram entre dois snapshots.
- Reporting lag: diferença entre progresso do município e progresso nacional/estadual.
- Antecipação: usar municípios já apurados para estimar municípios ainda ausentes, com base em relações históricas e socioeconômicas.

Resultado esperado: um sistema que, a cada snapshot, estime não apenas “quem está na frente”, mas como a composição geográfica dos votos ainda não totalizados tende a alterar o resultado final.